


۱- الف) نادرست است، مثال نقض: حالتی را بگیری که یک مسیر reward کمتر دهنده داشته باشد ولی مسیر دیگر دهنده باشد بیشتر از T است و reward بیشتری دارد، در این صورت شکل زیر را در نظر بگیر:



در این صورت داریم که:

$$V_i, V_0(S_i) = 0$$

value

Iteration

در یک مرحله بعد از آن $V_1(S_0) = 1$ و $V_1(S_{T+4}) = 10$ ، در مرحله i داریم که

$$V_i(S_0) = 1, V_i(S_{T+4}) = 10, V_i(S_{T+5}) = 2$$

در این شرایط $\pi(S_0)$ شرایط گفته شده را دارد چون T مرحله تعیین کننده است ولی Policy بعینه نیست.

ب) غلط است، Q-learning، بعین نتیجه اینکه سیاست ما بعینه نیست یا خیر، حتی اگر sub-optimal هم باشد، coverage می کند و جواب بعینه برابر Q-value ها را به ما می دهد یعنی که action ها را بعینه باشد در نهایت Q-value ها به مقادیر بعینه coverage می کند.

$$Q(s,a) \leftarrow (1-\alpha)Q(s,a) + \alpha[\text{sample}]$$

$$\alpha \rightarrow 1 \rightarrow Q(s,a) = \alpha \text{ sample}$$

عملاً هیچ استفاده ای از Policy نمی کنیم و جواب sample بعینه که گرفته ایم، اینست می کنیم - ابتدا coverage اتفاق نمی افتد، مقادیر بعینه Q-value ها بعینه نمی آید.

(د) درست است.

بسیار iteration در:


$$\text{Value-iteration} = O(|S^2A|)$$

$$\text{Policy-iteration} = O(|S^2A|) \xrightarrow[|A| \ll |S|]{|A| \ll |S|} O(|S^2A|) = O(|S^2|)$$


است

ارز زمانی Value-iteration و Policy iteration برابر می شود \Rightarrow

(ه) نادرست است:



در نظر بگیرید که



منطقی است که از S_0 به S_4 بر روی چون reward بیشتری می گیریم

حالا آن تمام رها با 1 جمع کنیم، مسیر $S_0 \xrightarrow{*} S_3$ ، reward ای برابر؟

خواهد داشت و مسیر $S_0 \rightarrow S_4$ ، reward ای برابر؟ خواهد داشت \leftarrow

Policy یعنی عوف می شود

$$V_0(i, j) = 0 \leftarrow V_{i,j}$$

۲- در ابتدا داریم که

برای حالتی خاص

$$V_k(s) = \max_{\alpha} \sum_{s'} T(s, \alpha, s') [R(s, \alpha, s') + \gamma V_k(s')]$$

مرحله اول

$$\Rightarrow V_1(1, 1) = 0 \rightarrow \text{به جوابی که به آن برابری می‌رسد}$$

$$V_1(1, 1) = 0 \rightarrow d/u/l/r$$

$$V_1(1, 1) = \max \left(\begin{matrix} r & L & u & d \\ 0/1 & (-\infty) & 0 & 0 \end{matrix} \right) = 0$$

$$V_1(1, 2) = \max \left(\begin{matrix} r & L & u & d \\ 0/1 & (\infty) & 0 & 0 \end{matrix} \right) = 0$$

V_1	V_2	V_3
0	4	0
0	0	0
b_1	b_2	b_3

$$V_1(1, 3) = 0$$

$$V_1(2, 3) = 0$$

جانبی نداریم \leftarrow احتمال می‌دهیم که فترت می‌شود

تستی می‌کنیم تا ببینیم

$$\text{مرحله دوم} \quad V_2(1, 1) = \max \left(\begin{matrix} r & L & u & d \\ 0 & 0 & 0 & 0 \end{matrix} \right) = 0$$

$$V_2(1, 2) = \max \left(\begin{matrix} r & L & u & d \\ 0/1 & (0 \times 4) & 0 \times 0 & 0 \times (0 \times 4) \end{matrix} \right) = 2, 1, 1$$

$$V_2(1, 2) = \max \left(\begin{matrix} r & L & u & d \\ 0/1 & (-\infty) + 0 \times (0 \times 4) & 0 \times (0 \times 4) & 0 \times (-\infty) + 0 \times (0 \times 4) \end{matrix} \right)$$

$$0/1(-\infty) = 2, 1, 1$$

$$V_2(1, 2) = \max \left(\begin{matrix} r & L & u & d \\ 0/1 & (\infty) & 0 \times (0 \times 4) & 0 \times (0 \times 4) + 0 \times (\infty) \end{matrix} \right)$$

$$0/1(\infty) = 2, 1, 1$$

$$V_2(1, 3) = 0$$

$$V_2(2, 3) = 0$$

V_1	V_2	V_3
2, 1, 1	2, 1, 1	0
0	2, 1, 1	0
b_1	b_2	b_3

$$V_r(1,1) = \max \left(\begin{aligned} &0.1 \wedge (0.9 \times 1.1) + 0.1 \times (0.9 \times 1.1), \quad 0.1 \times (0.9 \times 1.1), \quad 0.1 \wedge (1.1 \times 0.9) \\ &+ 0.1 \times (0.9 \times 1.1), \quad 0.1 \wedge (0.9 \times 1.1) \end{aligned} \right) = 1.1$$

$$V_r(1,2) = \max \left(\begin{aligned} &0.1 \wedge (0.9 \times 1.1) + 0.1 \wedge (0.9 \times 1.1), \quad 0.1 \wedge (0.9 \times 1.1) + 0.1 \wedge (0.9 \times 1.1), \\ &0.1 \wedge (0.9 \times 1.1) + 0.1 \wedge (0.9 \times 1.1) + 0.1 \times (0.9 \times 1.1), \quad 0.1 \times (0.9 \times 1.1) \\ &+ 0.1 \times (0.9 \times 1.1) \end{aligned} \right) = 1.1$$

$$V_r(1,3) = \max \left(\begin{aligned} &0.1 \wedge (-\infty) + 0.1 \wedge (1.1 \times 0.9) + 0.1 \times (0.9 \times 1.1), \quad 0.1 \wedge (0.9 \times 1.1) + 0.1 \times (0.9 \times 1.1) \\ &0.1 \wedge (0.9 \times 1.1) + 0.1 \times (-\infty), \quad 0.1 \wedge (0.9 \times 1.1) + 0.1 \wedge (-\infty) \end{aligned} \right) = 1.1$$

$$V_r(2,2) = \max \left(\begin{aligned} &0.1 \wedge (\infty) + 0.1 \wedge (0.9 \times 1.1) + 0.1 \wedge (0.9 \times 1.1), \quad 0.1 \wedge (0.9 \times 1.1) + 0.1 \times (0.9 \times 1.1) \\ &+ 0.1 \wedge (0.9 \times 1.1), \quad 0.1 \wedge (0.9 \times 1.1) + 0.1 \wedge (\infty) + 0.1 \wedge (0.9 \times 1.1), \\ &0.1 \wedge (1.1 \times 0.9) + 0.1 \wedge (\infty) + 0.1 \wedge (0.9 \times 1.1) \end{aligned} \right) = 1.1$$

$$V_r(1,3) = 0$$

$$V_r(2,3) = 0$$

ب) باید از الگوریتم‌های RL استفاده کنیم

model-based learning، در این روش عامل با مشاهده محیط مقادیرهای $T(s, a, s')$ و $R(s, a, s')$ رابطه‌ی تخمینی بدست آورد. سپس بعد از بدست آوردن مقادیر، MDP را حل می‌کنیم.
ایکسپلوراسیون

Passive RL، در این روش یک Policy ثابت تصادفی انتخاب می‌کنیم و هر بار Q-value های استیتهای جمع شده را آپدیت می‌کنیم و این فرایند را برای چند episode می‌دهیم و در نهایت مانند یک درخت expectimax، Policy، بهترین انتخاب می‌کنیم.
Active RL، علاوه بر مقادیر که در Passive حساب می‌شود، Policy را هم در طول کار یاد می‌گیریم.
در هر مرحله سیاست بهینه‌ای را که تا الان بدست آورده ایم را استفاده می‌کنیم.
ε-greedy هر طور که به احتمال ε از Policy فعلی پیروی نمی‌کند، رندوم عمل می‌کند.

(ج) (۱۳) - (۱۲) - (۱۱)

$$\text{sample} = R(s, \pi(s), s') + \gamma V^{\pi}(s')$$

$$V^{\pi}(s) \leftarrow (1-\alpha)V^{\pi}(s) + \alpha [\text{sample}]$$

$$\text{sample}_1 = 0 + 0.9(0) = 0 \rightarrow V^{\pi}(1,1) = 0$$

$$\text{sample}_2 = -5 + 0.9(0) = -5 \rightarrow V^{\pi}(1,2) = 0 + 0.9(-5) = -4.5$$

$$(1,1) - (1,2) - (2,2) - (2,3)$$

در مسیر بعدی

$$\text{sample}_3 = 0 + 0.9(-4.5) = -4.05 \rightarrow V^{\pi}(1,1) = 0 + 0.9(-4.5) = -4.05$$

$$\text{sample}_4 = 0 + 0.9(0) = 0 \rightarrow V^{\pi}(1,2) = 0.9(-4.5) + 0.1(0) = -4.05$$

$$\text{sample}_5 = 5 + 0.9(0) = 5 \rightarrow V^{\pi}(2,2) = 0.9(0) + 0.1(5) = 0.5$$

بقیه هم صفر هستند.

۳-۱) استفاده از Q-learning از خانه (0,0) شروع می‌کنیم و سپس هر بار که یک sample یادگیر با استفاده از معادلات بازن بردارسانی می‌کنیم.

$$V^*(s) = \max_{\alpha} Q(s, \alpha)$$

$$Q^*(s, \alpha) = \sum_{s'} T(s, \alpha, s') [R(s, \alpha, s') + \gamma V^*(s')]$$

$$V^*(s) = \max_{\alpha} \sum_{s'} T(s, \alpha, s') [R(s, \alpha, s') + \gamma V^*(s')]$$

چون T و R وابسته به یادگیرنده سعی می‌کنند تا sample های از محیط دریافت کنند و مقادیر Q-value را یادگیرند.



$$\text{sample} = R(s, \alpha, s') + \gamma \max_{\alpha'} Q(s', \alpha')$$

$$Q(s, \alpha) \leftarrow Q(s, \alpha) + \alpha (\text{sample} - Q(s, \alpha))$$

ابتدا همگی Q ها را صفر می‌گذاریم پس هر خانه معادل یک state است و هر

جست معادل action است. پس در هر ایندکس مسیر را از شروع

تا پایان می‌رویم و در این زمان نیز عملیات learning را انجام می‌دهیم.



با دو تا مسیر می‌گیریم.

$$Q((0,0),r) = 0 + \underset{\downarrow \text{right}}{(1-\alpha)Q(s,m)} + \underset{R(s,a), s'}{\alpha} \underset{\gamma \max_{a'} Q(s',a')}{\gamma} (-1 + 0) = -\gamma$$

$$Q((0,1),r) = 0 + \gamma(-1 + 0) = -\gamma$$

$$Q((0,2),r) = 0 + \gamma(-1 + 0) = -\gamma$$

$$Q((0,2),u) = 0 + \gamma(-1 + 0) = -\gamma$$

$$Q((1,2),u) = 0 + \gamma(-1 + 0) = -\gamma$$

$$Q((2,2),u) = 0 + \gamma(1 + 0) = \gamma$$

بقیه صفر

در جلسه دوم

$$Q((0,0),u) = 0 + \gamma(-1 + 0) = -\gamma$$

$$Q((1,0),u) = 0 + \gamma(-1 + 0) = -\gamma$$

$$Q((2,0),r) = 0 + \gamma(-1 + 0) = -\gamma$$

$$Q((2,1),u) = 0 + \gamma(-1 + 0) = -\gamma$$

$$Q((3,1),r) = 0 + \gamma(-1 + 0) = -\gamma$$

$$Q((3,2),r) = 0 + \gamma(1 + 0) = \gamma$$

ج) نقش اکتشاف، در این الگوریتم، $exploration$ نقش دارد که ما محیط را به طور کامل مشاهده کنیم، ممکن است پاداش های احتمالی زیادی وجود داشته باشد. باشند که آن ها را ندیده ایم و با $exploration$ آن ها را می بینیم → در اینجا کنترل جمعیت داریم جواب کاربرد دارد

نقش استفاده از اطلاعات، در ^{این} الگوریتم، exploration نقش مهمی دارد
ما ^{یک} سیاستی که تا الان به دست آمده است استفاده کنیم تا سیاستمان ناگهانی
تغییر نکند و در نهایت converge کند، که استفاده از اطلاعات کم باشد
مدل به دست به اکتشاف مان وابسته خواهد بود و حرکات تصادفی زیادی شود
مدت زمان زیادی طول می کشد تا ^{الگوریتم} converge کند. ← استفاده از اطلاعات
گذشته در converge کردن الگوریتم مؤثر است.

برای greedy - ϵ ، ابتدا مقدار ϵ را زیاد می گذاریم چون در ابتدا لازم است که
در محیط جستجو کنیم و اطلاعات به دست آوریم، ولی رفته رفته ϵ را باید کم کنیم
و حرکت به سمت بهینه شدن

تا تأثیر exploitation بیشتر شود، agent ما سیاست بهینه خود را
پیدا کند. اینکه مناطقی که از محیط به دست آورده ایم را استفاده می کنیم
همچنین الگوریتم زودتر همگرا شود برای همین هر یک مقدار برای کمترین مقدار
 ϵ و یک مقدار برای نرخ کم شدن ϵ در نظر می گیریم.

$$V^*(s) = \max_a Q^*(s, a) = Q^*(s, \pi^*(s)) \quad (۴- الف)$$

$$\Rightarrow V^*(s) - Q^*(s, \pi(s)) = Q^*(s, \pi^*(s)) - Q^*(s, \pi(s))$$

نشان بدهیم معادل ماکزیمم است ← برای هر s و a داریم:

$$\| \tilde{Q}(s, a) - Q^*(s, a) \|_{\infty} \leq \epsilon \Rightarrow$$

$$\Rightarrow \begin{cases} \tilde{Q}(s, a) - Q^*(s, a) \leq \epsilon \\ Q^*(s, a) - \tilde{Q}(s, a) \leq \epsilon \end{cases}$$

$$\xrightarrow{\pi(s), a} V^*(s) - Q^*(s, \pi(s)) = Q^*(s, \pi^*(s)) - Q^*(s, \pi(s)) \\ \leq Q^*(s, \pi^*(s)) + \epsilon - \tilde{Q}(s, \pi(s))$$

حالا چون $\tilde{Q}(s, \pi(s)) \geq \tilde{Q}(s, \pi^*(s))$ داریم:

$$Q^*(s, \pi^*(s)) + \epsilon - \tilde{Q}(s, \pi(s)) \leq \underbrace{Q^*(s, \pi^*(s)) + \epsilon - \tilde{Q}(s, \pi^*(s))}_{\text{کوچکتر مساوی } \epsilon} \leq 2\epsilon$$

$$\Rightarrow Q^*(s, \pi^*(s)) + \epsilon - \tilde{Q}(s, \pi^*(s)) \leq 2\epsilon$$

$$\Rightarrow V^*(s) - Q^*(s, \pi(s)) \leq Q^*(s, \pi^*(s)) + \epsilon - \tilde{Q}(s, \pi^*(s)) \leq 2\epsilon$$

$$\Rightarrow V^* - Q^*(s, \pi(s)) \leq 2\epsilon$$

(ب) از نامساوی بخش قبل داریم که

$$\textcircled{b} \quad V^*(s) - V_{\pi}(s) \leq Q^*(s, \pi(s)) + \gamma \varepsilon - V_{\pi}(s) = \gamma \varepsilon + Q^*(s, \pi(s)) - \tilde{Q}(s, \pi(s))$$

$$Q^*(s, \pi(s)) - \tilde{Q}(s, \pi(s)) =$$

$$\sum_{s'} T(s, \pi(s), s') [\cancel{R(s, \pi(s), s')} + \gamma V^*(s')] - \sum_{s'} T(s, \pi(s), s') [\cancel{R(s, \pi(s), s')} + \gamma V_{\pi}(s')]$$

$$= \gamma \sum_{s'} T(s, \pi(s), s') [V^*(s') - V_{\pi}(s')] \leq \gamma \max_{s'} (V^*(s') - V_{\pi}(s'))$$

$$\times \sum_{s'} T(s, \pi(s), s') \rightarrow 1$$

$$= \gamma \max_{s'} (V^*(s') - V_{\pi}(s'))$$

در نامساوی اول این قسمت می‌دانیم که به ازای هر s برقرار است \Leftarrow برای s که s را می‌گیریم
آنرا ماکزیمم می‌کنیم

$$\max_s (V_s^* - V_{\pi}(s)) \leq \gamma \varepsilon + \gamma \max_{s'} (V^*(s') - V_{\pi}(s'))$$

$$\Rightarrow \max_s (V_s^* - V_{\pi}(s)) \leq \frac{\gamma \varepsilon}{1 - \gamma}$$

$$\Rightarrow \forall s, V^*(s) - V_{\pi}(s) \leq \max_s (V^*(s) - V_{\pi}(s)) \leq \frac{\gamma \varepsilon}{1 - \gamma} \Rightarrow \underline{V_{\pi}(s) \geq V^*(s) - \frac{\gamma \varepsilon}{1 - \gamma}}$$

(2) برای بدست آوردن $V^*(s_1)$ و $V^*(s_2)$ ، از s_1 باید به s_2 برویم تا پاداش مثبتی بگیریم.
 برای s_2 هر قوطی می توانست در خودش بماند و حالا طبق معادله داریم:

$$V^*(s) = \max_a Q^*(s, a)$$

T ها مشخص و deterministic هستند و محال احتمال وقوع قطعی یک action هستند
 یا عدم وقوع قطعی

a ← ماندن
 b ← رفتن

$$\begin{aligned} V^*(s_1) &= \max \left(\begin{aligned} &\overset{a}{\uparrow} T(s_2, a, s_2) (R(s_2, a, s_2) + \gamma V^*(s_2)) + \\ &\overset{b}{\leftarrow} T(s_2, b, s_1) (R(s_2, b, s_1) + \gamma V^*(s_1)) \end{aligned} \right. \\ &\quad \left. \begin{aligned} &\overset{a}{\uparrow} T(s_2, a, s_2) (R(s_2, a, s_2) + \gamma V^*(s_2)) + \\ &\overset{b}{\leftarrow} T(s_2, b, s_1) (R(s_2, b, s_1) + \gamma V^*(s_1)) \end{aligned} \right) \\ &= 12 + \gamma V^*(s_2) \Rightarrow \boxed{V^*(s_2) = \frac{12}{1-\gamma}} \end{aligned}$$

$$\begin{aligned} V^*(s_1) &= \max \left(\begin{aligned} &\overset{a}{\uparrow} T(s_1, a, s_1) (R(s_1, a, s_1) + \gamma V^*(s_1)) + \\ &\overset{b}{\leftarrow} T(s_1, b, s_2) (R(s_1, b, s_2) + \gamma V^*(s_2)) \end{aligned} \right. \\ &\quad \left. \begin{aligned} &\overset{a}{\uparrow} T(s_1, a, s_1) (R(s_1, a, s_1) + \gamma V^*(s_1)) + \\ &\overset{b}{\leftarrow} T(s_1, b, s_2) (R(s_1, b, s_2) + \gamma V^*(s_2)) \end{aligned} \right) \end{aligned}$$

حالا وضع است که $V^*(s_1) \neq R(s_1, a, s_1) + \gamma V^*(s_1)$ چرا که در آن صورت $V^*(s_1) = 0$

$$V^*(s_1) = R(s_1, b, s_2) + \gamma V^*(s_2) \rightarrow V^*(s_1) = 12 + \frac{12\gamma}{1-\gamma} = \frac{12}{1-\gamma}$$

حال مقبله $Q^*(s_{1,a})$ را حساب می‌کنیم

$$Q^*(s_{1,a}) = T(s_{1,a}, s_2) (R(s_{1,a}, s_2) + \gamma V^*(s_2)) + T(s_{1,a}, s_1) (R(s_{1,a}, s_1) + \gamma V^*(s_1)) = \frac{28}{1-\gamma}$$

$$Q^*(s_{1,b}) = \cancel{T(s_{1,b}, s_2)} T(s_{1,b}, s_2) (R(s_{1,b}, s_2) + \gamma V^*(s_2)) + T(s_{1,b}, s_1) (R(s_{1,b}, s_1) + \gamma V^*(s_1)) = 28 + \gamma V^*(s_1) = \frac{28}{1-\gamma}$$

(ب) حالا می‌کنیم که اگر $\tilde{Q}(s_{1,a}) = \tilde{Q}(s_{1,b}) = \frac{(1+\gamma)\epsilon}{1-\gamma}$ ، آنگاه شرایط مسئله برقرار است.

$$|\tilde{Q}(s_{1,a}) - Q^*(s_{1,a})| = \left| \frac{(1-\gamma)\epsilon}{1-\gamma} \right| = \epsilon \leq \epsilon$$

$$|\tilde{Q}(s_{1,b}) - Q^*(s_{1,b})| = \left| \frac{(1+\gamma)\epsilon}{1-\gamma} - \frac{28}{1-\gamma} \right| = \left| \frac{(1-\gamma)\epsilon}{1-\gamma} \right| = \epsilon \leq \epsilon$$

که نتیجه می‌دهد خطای \tilde{Q} حداکثر ϵ است. حال چون

$$\tilde{Q}(s_{1,a}) = \tilde{Q}(s_{1,b}) \rightarrow \pi(s_1) = \underset{a}{\operatorname{argmax}} \tilde{Q}(s_{1,a})$$

می‌توان دید که در هر مرحله action s را انتخاب کردی

$$V\pi(s_1) = R(s_{1,a}, s_1) + \gamma V\pi(s_1) \Rightarrow V\pi(s_1) = 0$$

چون عامل همیشه عمل مانند انجام می‌دهد

$$V\pi(s_1) - V^*(s_1) = 0 - \frac{28}{1-\gamma} = -\frac{28}{1-\gamma}$$

۵- الف) در مرحله اول یادگیری میسر می‌گردد: $r_0 = 0$ و در بقیه مراحل یادگیری میسر می‌گردد $r_t = 1$

$$\sum_{t=0}^{\infty} \gamma^t r_t = \sum_{t=1}^{\infty} \gamma^t = \frac{1}{1-\gamma} - 1 = \frac{\gamma}{1-\gamma}$$

ب) در مرحله اول یادگیری میسر می‌گردد و در بقیه مراحل میسر می‌گردد $\frac{\gamma^2}{1-\gamma}$

$$r_0 = \frac{\gamma^2}{1-\gamma}, r_t = 0 \quad \forall t \geq 1 \Rightarrow \sum_{t=0}^{\infty} \gamma^t r_t = \frac{\gamma^2}{1-\gamma}$$

حالا چون $\gamma < 1 \Rightarrow \frac{\gamma^2}{1-\gamma} < \frac{\gamma}{1-\gamma}$ عمل بهینه a_1

است \leftarrow با a_1 به s_1 می‌رویم.

$$V_{n+1}(s) = \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V_n(s')] \quad (ع)$$

برای حالت s_0 تنها مقدارهای $T(s_0, a_1, s_1) = T(s_0, a_2, s_2) = 1$ میسر اند.

$$\Rightarrow V_{n+1}(s_0) = \max \left(R(s_0, a_1, s_1) + \gamma V_n(s_1), R(s_0, a_2, s_2) + \gamma V_n(s_2) \right)$$

$$= \max \left(\sum_{t=1}^n \gamma^t, \frac{\gamma^2}{1-\gamma} \right) \quad \text{و } \cancel{V_n(s_0)}$$

حالا حالتی بهینه است که $\sum_{t=1}^n \gamma^t > \frac{\gamma^2}{1-\gamma}$ برای اینکه action

a_1 را انتخاب کنی و به s_1 بروی.

$$V_{n^*}(s_0) = \sum_{t=1}^{n^*} \gamma^t \Rightarrow \sum_{t=1}^{n^*} \gamma^t \geq \frac{\gamma^r}{1-\gamma} \Rightarrow \gamma \left(\frac{1-\gamma^{n^*}}{1-\gamma} \right) \geq \frac{\gamma^r}{1-\gamma} \rightarrow$$

$$1-\gamma^{n^*} \geq \gamma \rightarrow 1-\gamma \geq \gamma^{n^*} \xrightarrow{\log} n^* \log \gamma \leq \log(1-\gamma)$$

توجه کنید
 $\log \gamma < 0$

$$\rightarrow n^* \geq \frac{\log(1-\gamma)}{\log(\gamma)}$$

این مقدار ثابت است.